

Detecção Híbrida de Fraudes Financeiras com Random Forest, Heurísticas de Negócio e Engenharia de Atributos Comportamentais

1st Caroline Silva Grizante

Fundação Hermínio Ometto – Araras
carolinegrizante105@alunos.fho.edu.br

2nd Emilly Emanuely Ribeiro dos Santos

Fundação Hermínio Ometto – Araras
emillyribeiro@alunos.fho.edu.br

3rd Marcela Lovatto

Fundação Hermínio Ometto – Araras
marcela.lovatto@alunos.fho.edu.br

Resumo—A detecção de fraudes financeiras é um problema de classificação supervisionada caracterizado por forte desbalanceamento de classes, evolução contínua dos padrões de ataque e elevado custo operacional associado tanto a falsos negativos quanto a falsos positivos. Este artigo apresenta o desenvolvimento e a avaliação experimental de uma abordagem híbrida para detecção de fraudes em transações financeiras, combinando um classificador Random Forest com heurísticas de negócio codificadas em um atributo derivado denominado *score_heuristico*. O estudo utiliza como ponto de partida a base pública *Credit Card Fraud Detection*, disponibilizada no Kaggle, e realiza enriquecimento controlado por simulação para adicionar atributos comportamentais e contextuais ausentes na base original. A metodologia inclui caracterização da base pública, criação de variáveis sintéticas, pseudonimização de identificadores simulados, engenharia de atributos comportamentais, simulação de cenários adversos, tratamento de valores ausentes, ajuste para desbalanceamento de classes e comparação entre SMOTE e ADASYN. Os experimentos foram conduzidos em cenários controlados que representam situações como carding, ataques de velocidade, falhas sucessivas de autenticação, transações internacionais, contas antigas comprometidas e perfis legítimos de alto valor. Os resultados indicam que a acurácia permaneceu elevada em todos os cenários avaliados, enquanto o recall apresentou maior sensibilidade às perturbações introduzidas, variando principalmente nos cenários com ruído, camuflagem e oversampling via SMOTE. No cenário avaliado, o ADASYN restaurou o recall observado no cenário de referência, sugerindo potencial vantagem de estratégias adaptativas de reamostragem para amostras de difícil classificação. O estudo também discute limitações metodológicas relevantes, incluindo ausência de validação temporal, possível dependência entre regras de simulação e atributos de decisão, risco de vazamento temporal em atributos históricos, uso de variáveis simuladas e necessidade de avaliação futura contra ataques de inferência de membro.

Palavras-chave—Detecção de Fraudes, Random Forest, Aprendizado de Máquina, Dados Desbalanceados, Heurísticas de Negócio, Pseudonimização, Ataques de Inferência de Membro, Membership Inference Attacks.

I. INTRODUÇÃO

O crescimento das transações digitais ampliou a superfície de ataque em sistemas financeiros, especialmente em ambientes de pagamento remoto, comércio eletrônico e autenticação distribuída. Nesse contexto, a detecção de fraudes tornou-se um problema crítico de segurança e inteligência computacional, pois fraudes representam eventos raros, dinâmicos e frequentemente projetados para se assemelhar a transações

legítimas. Além do prejuízo financeiro direto, decisões incorretas de sistemas antifraude podem afetar a experiência do usuário: falsos negativos permitem a passagem de transações fraudulentas, enquanto falsos positivos bloqueiam clientes legítimos e aumentam o atrito operacional.

Modelos de aprendizado de máquina têm sido amplamente utilizados nesse domínio, pois conseguem identificar padrões não triviais em grandes volumes de dados transacionais. Trabalhos recentes investigam diferentes algoritmos para detecção de fraude com cartões de crédito, incluindo métodos tradicionais de aprendizado supervisionado e arquiteturas de aprendizado profundo [1]. Entretanto, a aplicação direta desses modelos enfrenta três desafios principais. Primeiro, a classe fraudulenta costuma representar uma fração muito pequena do conjunto de dados, tornando a acurácia isolada uma métrica insuficiente. Segundo, ataques modernos, como carding, tomada de conta e tentativas automatizadas de autenticação, dependem de sinais contextuais e temporais que nem sempre estão explícitos nos dados brutos. Terceiro, o uso de dados financeiros sensíveis exige medidas de governança e privacidade, uma vez que modelos treinados sobre registros individuais podem vaziar informações sobre seus dados de treinamento [2].

Historicamente, sistemas antifraude baseados em regras foram utilizados por sua interpretabilidade e facilidade de auditoria. Contudo, regras estáticas tendem a ser rígidas e podem ser contornadas por fraudadores adaptativos. Por outro lado, modelos puramente estatísticos podem capturar interações complexas, mas nem sempre representam adequadamente conhecimento de domínio, como o efeito atenuante de autenticação biométrica ou a diferença entre uma compra internacional legítima de cliente recorrente e uma transação de risco. Assim, uma alternativa prática consiste em combinar regras de negócio e aprendizado supervisionado em uma arquitetura híbrida.

Este trabalho apresenta uma abordagem híbrida para detecção de fraudes financeiras baseada em Random Forest [3] e em um conjunto de heurísticas de negócio convertidas em atributo numérico. Como base pública de referência e ponto de partida, utiliza-se o conjunto *Credit Card Fraud Detection*, do Kaggle [7]. Entretanto, como essa base contém atributos anonimizados por PCA e não inclui variáveis operacionais como país da transação, tipo de autenticação, idade da conta

ou falhas de autenticação, este estudo realiza enriquecimento sintético controlado para representar cenários comportamentais típicos de sistemas antifraude.

A hipótese experimental é que a incorporação de atributos comportamentais e contextuais, como *valor_relativo*, *falha_autenticacao*, *ataque_velocity*, *pais_diferente* e *score_heuristico*, pode aumentar a capacidade do modelo de diferenciar transações legítimas e fraudulentas em cenários adversos simulados. Ao mesmo tempo, reconhece-se que resultados obtidos em ambiente enriquecido e simulado não equivalem a validação direta em ambiente bancário real.

As principais contribuições deste artigo são:

- 1) desenvolvimento de uma arquitetura híbrida que integra heurísticas de negócio como atributo derivado em um classificador Random Forest;
- 2) explicitação da relação entre a base pública do Kaggle e os atributos adicionais simulados, evitando tratar variáveis enriquecidas como se estivessem presentes no conjunto original;
- 3) construção de atributos comportamentais e contextuais voltados a cenários modernos de fraude, incluindo carding, ataques de velocidade, falhas de autenticação, variação geográfica e desvio em relação ao histórico de consumo;
- 4) avaliação experimental em 20 cenários controlados de estresse, incluindo remoção de atributos, dados ausentes, desbalanceamento extremo, oversampling e estudos de ablação;
- 5) comparação entre estratégias de tratamento de desbalanceamento, com ênfase em *class weight*, SMOTE [4] e ADASYN [5];
- 6) discussão crítica sobre privacidade, pseudonimização, vazamento temporal, riscos de dependência entre regras de simulação e atributos de decisão, e ataques de inferência de membro.

O restante do artigo está organizado da seguinte forma. A Seção II apresenta os trabalhos relacionados. A Seção III descreve a metodologia, incluindo dados, pré-processamento, engenharia de atributos, modelo e validação. A Seção IV discute os resultados experimentais. A Seção V apresenta as conclusões, limitações e direções para trabalhos futuros.

II. TRABALHOS RELACIONADOS

A detecção de fraudes em cartões e transações financeiras tem sido estudada por meio de algoritmos supervisionados, técnicas de reamostragem e arquiteturas híbridas. Alarfaj *et al.* [1] investigaram algoritmos de aprendizado de máquina e aprendizado profundo para detecção de fraude com cartões de crédito, destacando o impacto do desbalanceamento de classes e a necessidade de métricas além da acurácia. Embora modelos complexos possam melhorar a capacidade preditiva, sua adoção prática exige atenção ao custo dos falsos positivos e à interpretabilidade das decisões.

Random Forest é uma técnica de aprendizado por conjunto proposta por Breiman [3], baseada na combinação de múltiplas árvores de decisão treinadas com aleatoriedade nos dados e nos

atributos. Sua aplicação em dados tabulares é adequada para cenários de fraude devido à capacidade de capturar relações não lineares, lidar com atributos heterogêneos e produzir medidas de importância de variáveis. Em comparação com uma árvore isolada, a agregação de múltiplas árvores reduz a variância e tende a melhorar a generalização.

O desbalanceamento de classes é um problema central em detecção de fraude. Quando a classe fraudulenta é rara, um classificador pode obter alta acurácia classificando quase todas as transações como legítimas. Para mitigar esse problema, Chawla *et al.* [4] propuseram o SMOTE, que gera amostras sintéticas da classe minoritária por interpolação entre exemplos próximos. Essa técnica reduz a dependência de simples duplicação de registros, mas pode introduzir amostras ambíguas quando as fronteiras entre classes são sobrepostas. He *et al.* [5] propuseram o ADASYN, que adapta a geração de amostras sintéticas às regiões de maior dificuldade de aprendizagem, concentrando novos exemplos onde a classe minoritária está mais próxima da majoritária.

Além de Random Forest e técnicas clássicas de reamostragem, trabalhos recentes também exploram modelos baseados em gradient boosting, redes generativas e autoencoders variacionais para detecção de fraudes. Taha e Malebary [8] investigaram o uso de LightGBM otimizado para detecção de fraude com cartões de crédito. Ghaleb *et al.* [9] combinaram estratégias generativas de oversampling com Random Forest, explorando a geração de amostras sintéticas para mitigar o desbalanceamento. Huang *et al.* [10], por sua vez, avaliaram o uso de autoencoders variacionais no contexto de detecção de fraudes. Esses estudos indicam que abordagens modernas podem melhorar o desempenho, mas também reforçam a necessidade de avaliar custo computacional, interpretabilidade, robustez e risco de sobreajuste.

Além do desempenho preditivo, modelos treinados com dados sensíveis podem introduzir riscos de privacidade. Shokri *et al.* [2] demonstraram que modelos de aprendizado de máquina podem ser vulneráveis a ataques de inferência de membro, nos quais um atacante, mesmo com acesso de caixa-preta, tenta inferir se um registro específico participou do treinamento. O trabalho mostra que diferenças no comportamento do modelo entre registros vistos e não vistos podem ser exploradas por modelos de ataque, especialmente em situações de sobreajuste. No contexto financeiro, esse risco é relevante porque transações e padrões de consumo podem revelar informações sensíveis sobre indivíduos.

Como estratégia de mitigação, Yang *et al.* [6] propuseram um framework generativo com Variational Autoencoder (VAE), no qual os dados originais são mapeados para um espaço latente, perturbados por um mecanismo de privacidade métrica e reconstruídos como dados sintéticos. A proposta busca reduzir a exposição dos dados reais antes do treinamento do modelo-alvo, mantendo utilidade para tarefas de aprendizado. Esse tipo de abordagem é mais forte do que simples pseudonimização, pois atua na distribuição dos dados utilizados para treinamento; contudo, sua adoção exige avaliação formal de utilidade e privacidade.

O presente trabalho diferencia-se da literatura citada por priorizar uma abordagem híbrida orientada a atributos operacionais simulados: regras de negócio são transformadas em atributos aprendíveis pelo modelo, enquanto cenários adversos são simulados para avaliar robustez. Diferentemente de trabalhos centrados exclusivamente em modelos, este estudo enfatiza a interação entre engenharia de atributos, heurísticas, desbalanceamento e análise crítica de métricas. Ao mesmo tempo, reconhece que a avaliação de privacidade realizada neste trabalho é conceitual e baseada em pseudonimização, não substituindo testes formais contra ataques de inferência de membro.

III. METODOLOGIA

A metodologia foi estruturada em sete etapas: caracterização e enriquecimento dos dados, pseudonimização e governança, engenharia de atributos, construção do score heurístico, treinamento do modelo Random Forest, tratamento de desbalanceamento e avaliação experimental em cenários adversos.

A. Caracterização e Enriquecimento dos Dados

O estudo utilizou como ponto de partida o conjunto público *Credit Card Fraud Detection*, disponibilizado no Kaggle pelo Machine Learning Group da ULB [7]. A base original contém transações de cartão de crédito ocorridas em dois dias, com 284.807 transações e 492 registros fraudulentos. Os atributos *V1* a *V28* são componentes principais obtidos por PCA, enquanto *Time* e *Amount* não foram transformados por PCA. A variável *Class* é o rótulo binário, assumindo valor 1 para fraude e 0 para transação legítima [7].

Entretanto, a base original não contém informações operacionais como país usual do cliente, país da transação, tipo de autenticação, falhas de autenticação, idade da conta, cartão novo, risco do estabelecimento ou identificadores diretos de cliente. Portanto, este trabalho segue o caso em que a base Kaggle é utilizada como ponto de partida e enriquecida por simulação controlada. Os atributos comportamentais e contextuais empregados no modelo não são apresentados como variáveis originais do Kaggle; eles foram adicionados artificialmente para representar condições operacionais típicas de sistemas antifraude.

A Tabela I resume a rastreabilidade das variáveis utilizadas.

Tabela I
RASTREABILIDADE DAS VARIÁVEIS UTILIZADAS

Grupo	Origem no Experimento
Variáveis originais da base Kaggle	<i>Time</i> , <i>Amount</i> , <i>V1</i> – <i>V28</i> e <i>Class</i> .
Variáveis simuladas por enriquecimento	<i>pais_diferente</i> , <i>tipo_autenticacao_n</i> , <i>falha_autenticacao</i> , <i>ataque_velocity</i> , <i>cartao_novo</i> , <i>idade_conta_dias</i> e <i>risco_estabelecimento</i> .
Variáveis derivadas	<i>valor</i> , derivado de <i>Amount</i> ; <i>valor_relativo</i> , estimado a partir de histórico sintético por cliente; e <i>score_heuristico</i> , calculado por regras de negócio.

O enriquecimento foi realizado com o objetivo de representar cenários como carding, velocity attack, tentativa de força

bruta, tomada de conta antiga, transações internacionais de alto valor e perfis legítimos de clientes com comportamento excepcional. Essa estratégia permitiu avaliar o modelo em condições controladas; entretanto, por envolver simulação, os resultados devem ser interpretados como evidências internas do protótipo, não como validação definitiva em ambiente bancário real.

Também é importante observar que o atributo *Time* da base Kaggle representa segundos decorridos desde a primeira transação do conjunto, e não necessariamente um horário civil completo com data, fuso horário e contexto geográfico. Assim, variáveis como *transacao_noturna* foram tratadas como parte do enriquecimento experimental e não como informação operacional diretamente disponível na base original.

B. Pseudonimização e Governança dos Dados

A base Kaggle já é disponibilizada de forma anonimizada, com atributos principais transformados por PCA [7]. No pipeline enriquecido deste estudo, identificadores sintéticos de cliente foram utilizados apenas para possibilitar agregações comportamentais, como média histórica de consumo e cálculo de *valor_relativo*. Esses identificadores foram tratados de forma pseudonimizada, por meio de códigos alfanuméricos, evitando a exposição de nomes ou identificadores civis no ambiente experimental.

É importante distinguir pseudonimização de anonimização. A pseudonimização reduz a exposição direta de identidade, mas não elimina todos os riscos de reidentificação ou inferência. Em particular, ataques de inferência de membro exploram diferenças no comportamento do modelo entre registros usados e não usados no treinamento [2]. Portanto, neste trabalho, a pseudonimização é tratada como uma medida de governança e minimização de exposição, não como garantia formal contra ataques de privacidade.

Valores ausentes foram tratados por imputação pela mediana em atributos numéricos críticos, como *idade_conta_dias*, *valor_relativo* e *risco_estabelecimento*. Além disso, alguns experimentos introduziram valores nulos artificialmente para testar a estabilidade do pipeline diante de degradação de dados.

C. Engenharia de Atributos

A Tabela II resume os principais atributos utilizados. A engenharia de atributos buscou representar sinais transacionais, comportamentais e contextuais associados a risco de fraude.

O atributo *valor_relativo* é metodologicamente relevante, mas também representa uma possível fonte de vazamento temporal caso seja calculado com informações futuras ou com registros pertencentes ao conjunto de teste. Em uma implantação real, atributos históricos devem ser calculados apenas com informações disponíveis antes da transação corrente. Como este estudo utiliza split aleatório estratificado e histórico sintético, esse ponto é tratado como limitação e como requisito para versões futuras do pipeline.

D. Score Heurístico

O *score_heuristico* foi definido como um sistema de pontuação baseado em regras de negócio. Cada transação recebe

Tabela II
ATRIBUTOS UTILIZADOS NO MODELO HÍBRIDO

Atributo	Tipo	Justificativa
<i>valor</i>	Numérico	Valor bruto da transação, derivado de <i>Amount</i> . Pode indicar risco em compras de alto valor, mas é insuficiente isoladamente.
<i>valor_relativo</i>	Numérico	Razão entre o valor atual e o comportamento histórico sintético do cliente, permitindo detectar desvios individuais.
<i>pais_diferente</i>	Binário	Indica divergência entre o país usual simulado do cliente e o país simulado da transação.
<i>transacao_noturna</i>	Binário	Representa transações marcadas sinteticamente como noturnas, em janela equivalente ao intervalo entre 22h e 6h, período associado a menor interação do usuário.
<i>tipo_autenticacao_n</i>	Catégorico codificado	Representa o nível de robustez da autenticação, como senha, 2FA ou biometria.
<i>falha_autenticacao</i>	Numérico	Quantifica falhas de autenticação e auxilia na identificação de força bruta.
<i>ataque_velocity</i>	Binário	Indica múltiplas transações em rápida sequência, padrão compatível com carding.
<i>cartao_novo</i>	Binário	Representa transações associadas a cartões recém-emitados ou ativados.
<i>idade_conta_dias</i>	Numérico	Captura antiguidade sintética da conta, útil para diferenciar contas novas e contas antigas comprometidas.
<i>risco_estabelecimento</i>	Ordinal	Representa histórico simulado de risco associado ao estabelecimento ou categoria comercial.
<i>score_heuristico</i>	Numérico derivado	Agrega sinais agravantes e atenuantes definidos por regras de negócio.

inicialmente pontuação zero. Sinais associados a maior risco aumentam o score, enquanto fatores de confiança reduzem a pontuação. A Tabela III apresenta os pesos utilizados.

Tabela III
REGRAS UTILIZADAS NO SCORE HEURÍSTICO

Condição	Peso
<i>ataque_velocity</i> verdadeiro	+7
<i>falha_autenticacao</i> > 5	+6
<i>valor_relativo</i> > 5	+6
<i>idade_conta_dias</i> < 30	+5
<i>risco_estabelecimento</i> elevado	+5
<i>pais_diferente</i> verdadeiro	+4
<i>cartao_novo</i> verdadeiro	+4
<i>transacao_noturna</i> verdadeira	+3
Autenticação por biometria	-6
Autenticação por 2FA	-3
<i>idade_conta_dias</i> > 1000	-4

A decisão de incorporar o atributo *score_heuristico*, em vez de utilizá-lo como classificador isolado, foi tomada para permitir que o Random Forest aprendesse interações entre a heurística e os demais atributos. Por exemplo, uma transação internacional de alto valor pode ser suspeita em um cliente novo sem autenticação forte, mas aceitável em um cliente antigo autenticado por biometria. Essa interação é difícil de representar por uma regra única e rígida.

Entretanto, como o *score_heuristico* é calculado a partir de variáveis também fornecidas ao modelo, existe potencial redundância informacional. Além disso, quando os mesmos sinais são utilizados tanto na simulação de cenários fraudulentos quanto no treinamento do classificador, as métricas podem ser artificialmente elevadas. Por isso, os resultados deste trabalho são interpretados como avaliação controlada do protótipo e não como evidência definitiva de generalização.

E. Modelo e Configuração Experimental

O classificador principal foi o Random Forest [3], configurado com *n_estimators=200*, *max_depth=15* e *random_state=42*. A escolha foi motivada pela adequação do al-

goritmo a dados tabulares, sua robustez a relações não lineares e a possibilidade de análise de importância dos atributos.

Os dados foram divididos em treinamento e teste na proporção 80/20, com estratificação pela variável-alvo. Essa escolha preserva a proporção entre transações legítimas e fraudulentas nos subconjuntos. O desbalanceamento foi tratado por duas estratégias: uso de *class_weight='balanced_subsample'* e aplicação de oversampling no conjunto de treinamento em cenários específicos. O SMOTE foi utilizado para gerar amostras sintéticas por interpolação [4], enquanto o ADASYN foi utilizado para concentrar a geração sintética em regiões de maior dificuldade de classificação [5]. Para reduzir risco de vazamento, as técnicas de oversampling devem ser aplicadas apenas ao conjunto de treinamento, nunca ao conjunto de teste.

Reconhece-se que SMOTE e ADASYN podem produzir valores intermediários artificiais quando aplicados diretamente a atributos catégoricos ou binários codificados numericamente. Por exemplo, uma variável catégorica codificada como 0, 1 e 2 pode receber valores sintéticos contínuos sem interpretação operacional direta. Assim, versões futuras devem avaliar variantes apropriadas para dados mistos, como SMOTENC, ou aplicar oversampling somente sobre atributos contínuos adequadamente tratados.

Também se reconhece que o split aleatório estratificado é uma limitação para problemas financeiros temporais. Em produção, uma avaliação mais rigorosa deveria empregar divisão temporal e, quando possível, separação por cliente, reduzindo o risco de vazamento entre treino e teste.

F. Métricas de Avaliação

As métricas avaliadas foram acurácia, precision, recall, F1-score e matriz de confusão. A acurácia foi interpretada apenas como indicador geral de estabilidade, pois pode ser enganosa em classes fortemente desbalanceadas. O recall mede a proporção de fraudes efetivamente detectadas, enquanto a precision mede a proporção de alertas classificados como fraude que eram realmente fraudulentos. Em sistemas antifraude, ambas são relevantes: alto recall reduz perdas financeiras por frau-

des não detectadas, enquanto alta precision reduz bloqueios indevidos de clientes legítimos.

As métricas são definidas por:

$$Precision = \frac{TP}{TP + FP} \quad (1)$$

$$Recall = \frac{TP}{TP + FN} \quad (2)$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3)$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

em que TP representa verdadeiros positivos, TN verdadeiros negativos, FP falsos positivos e FN falsos negativos.

Devido ao forte desbalanceamento da base de referência, métricas baseadas na curva Precision-Recall, como PR-AUC ou AUPRC, seriam especialmente adequadas. No entanto, como nem todos os cenários experimentais mantiveram registros consolidados de probabilidades preditas, curvas Precision-Recall e PR-AUC não foram calculadas nesta versão. Essa ausência é tratada como limitação e como prioridade para trabalhos futuros.

IV. RESULTADOS E DISCUSSÃO

A. Resultados Gerais dos Cenários Experimentais

A Tabela IV apresenta os 20 cenários avaliados. Quando os valores de precision, F1-score, falsos positivos e falsos negativos não estavam disponíveis nos registros consolidados, eles foram indicados como –, evitando inferências não verificadas. Essa decisão preserva a rastreabilidade dos resultados e evita introdução de métricas não calculadas no experimento original. Em particular, quando a precision não estava disponível, o F1-score também foi marcado como –, pois essa métrica depende simultaneamente de precision e recall.

Os resultados mostram desempenho elevado na maior parte dos cenários. Entretanto, a presença de múltiplos resultados perfeitos deve ser analisada criticamente. Em problemas reais de fraude, desempenhos iguais a 1.0000 em vários cenários podem indicar que os padrões simulados estão fortemente separáveis, que os atributos derivados capturam diretamente a lógica de geração das fraudes ou que o conjunto de teste não representa casos suficientemente independentes. Assim, os resultados devem ser interpretados como validação interna de um protótipo experimental enriquecido por simulação, e não como evidência de desempenho generalizável para produção.

B. Análise dos Cenários Adversos

Os testes 3 e 7 avaliaram a remoção ou neutralização da variável *idade_conta_dias*. No teste 3, embora a acurácia tenha permanecido elevada, com valor de 0.9933, o recall caiu para 0.9333, indicando perda de sensibilidade na identificação de fraudes. Essa queda de desempenho sugere que o histórico da conta contribui para a decisão, mas não é o único fator relevante. A manutenção de desempenho ainda elevado indica que

outros atributos, como *score_heuristico*, *falha_autenticacao* e *transacao_noturna*, compensaram parcialmente a ausência de informação histórica.

Nos testes 11, 12 e 13, que introduziram camuflagem, dados nulos e desbalanceamento extremo, o recall caiu para 0.9744. Essa redução é metodologicamente relevante porque indica que cenários com maior ambiguidade afetam a sensibilidade do modelo. No teste 11, especificamente, a matriz de confusão disponível indicou ausência de falsos positivos e dois falsos negativos, sugerindo que o modelo permaneceu conservador em relação ao bloqueio de clientes legítimos, mas deixou de capturar parte das fraudes camufladas.

O teste 14, com SMOTE, apresentou a maior degradação observada entre os cenários destacados, com recall de 0.9000. A matriz de confusão associada indicou dois falsos positivos e dois falsos negativos. Esse comportamento sugere que, neste conjunto simulado, a interpolação sintética pode ter produzido exemplos próximos às fronteiras de decisão, aumentando a ambiguidade entre fraudes e transações legítimas. Essa interpretação é compatível com uma limitação conhecida de técnicas de oversampling quando as classes apresentam sobreposição.

No teste 16, o uso de ADASYN recuperou o desempenho no cenário avaliado. Como o ADASYN concentra a geração sintética em regiões de maior dificuldade de aprendizagem [5], o resultado sugere que a reamostragem adaptativa foi mais adequada do que o SMOTE para o arranjo experimental utilizado. Contudo, essa conclusão deve ser restrita ao conjunto de cenários avaliados, não sendo possível afirmar superioridade geral sem múltiplos datasets, validação cruzada e análise estatística.

C. Estudo de Ablação

Os testes 19 e 20 removeram, respectivamente, o *score_heuristico* e a combinação entre *score_heuristico* e *ataque_velocity*. O desempenho permaneceu em 1.0000 nos registros consolidados. Embora esse resultado pareça contradizer a hipótese de importância do score, ele pode ser explicado por redundância informacional entre os atributos. Como o *score_heuristico* é derivado de variáveis como falha de autenticação, país, horário, idade da conta e valor relativo, o Random Forest pode ter reconstruído implicitamente parte da regra a partir dos atributos originais.

Esse achado é relevante: a contribuição do score heurístico pode estar menos associada ao aumento direto de métricas em cenários altamente separáveis e mais relacionada à interpretabilidade, organização do conhecimento de domínio e estabilidade em cenários com menos dados. Assim, os experimentos de ablação sugerem que o *score_heuristico* não deve ser interpretado, nesta etapa, como responsável isolado pelo ganho preditivo, mas como um mecanismo de consolidação de conhecimento especialista e de apoio à interpretabilidade do pipeline. Para comprovar ganho preditivo independente, seria necessário comparar o modelo híbrido contra uma heurística isolada, um Random Forest sem atributos derivados e validação por múltiplos splits.

Tabela IV
RESUMO DOS RESULTADOS EXPERIMENTAIS EM CENÁRIOS CONTROLADOS

Teste	Característica do Cenário	Acc.	Prec.	Recall	F1	FP	FN
1	Transações noturnas e sem autenticação	1.0000	1.0000	1.0000	1.0000	0	0
2	Inserção de fraudes mais sensíveis	1.0000	–	1.0000	–	–	–
3	Remoção da variável <i>idade_conta_dias</i>	0.9933	0.9333	0.9333	0.9333	10	10
4	Uso do valor histórico médio por cliente	1.0000	–	1.0000	–	–	–
5	Validação de clientes legítimos em cenário de produção	1.0000	–	1.0000	–	–	–
6	Fraudes em contas não recentes	0.9998	0.9889	0.9889	0.9889	1	1
7	Neutralização de <i>idade_conta_dias</i>	0.9888	–	0.9888	–	–	–
8	Compras altas e internacionais por clientes legítimos	1.0000	–	1.0000	–	–	–
9	Fraudes de baixo valor associadas a carding	1.0000	1.0000	1.0000	1.0000	0	0
10	Erro humano de senha versus tentativa automatizada	1.0000	–	1.0000	–	–	–
11	Camuflagem: clientes VIP, dados nulos e contas antigas	0.9998	1.0000	0.9744	0.9870	0	2
12	Ruído: 5% de dados nulos em colunas críticas	0.9998	–	0.9744	–	–	–
13	Desequilíbrio acentuado: 0.4% de fraude	0.9998	–	0.9744	–	–	–
14	Oversampling com SMOTE	0.9996	0.9000	0.9000	0.9000	2	2
15	Oversampling com base mais sensível	1.0000	–	1.0000	–	–	–
16	Oversampling com ADASYN	1.0000	1.0000	1.0000	1.0000	0	0
17	Subconjunto balanceado manualmente	1.0000	–	1.0000	–	–	–
18	Estresse máximo com ruídos	1.0000	–	1.0000	–	–	–
19	Ablação: remoção do <i>score_heuristico</i>	1.0000	–	1.0000	–	–	–
20	Ablação: remoção de <i>ataque_velocity</i> e <i>score_heuristico</i>	1.0000	–	1.0000	–	–	–

Nota: '–' indica métrica não disponível nos registros consolidados do experimento. Quando a precision não estava disponível, o F1-score também foi marcado como – para evitar cálculo não auditável.

D. Discussão sobre Acurácia, Recall e Precision

A acurácia permaneceu próxima de 1.0000 em quase todos os cenários, mas essa métrica não deve ser interpretada isoladamente. Em bases com fraude rara, um classificador que prediz quase todas as transações como legítimas pode obter alta acurácia e, ainda assim, falhar em sua finalidade principal. Por isso, recall, precision e métricas baseadas na curva Precision-Recall são mais informativas.

O recall indica a capacidade de capturar fraudes reais. Em cenários críticos, como camuflagem e SMOTE, a queda do recall revelou sensibilidade do modelo à ambiguidade dos dados. A precision, por sua vez, é diretamente associada ao controle de falsos positivos. Nos cenários em que a matriz de confusão estava disponível, observou-se que o teste 11 manteve precision 1.0000, enquanto o cenário com SMOTE apresentou precision 0.9000, indicando aumento de alertas indevidos.

Em aplicações reais, a escolha do limiar de decisão deveria ser ajustada conforme o custo relativo entre falsos positivos e falsos negativos. Um limiar mais baixo tende a aumentar recall, mas pode reduzir precision. Um limiar mais alto reduz bloqueios indevidos, mas pode permitir a passagem de fraudes. Esse *trade-off* deve ser tratado como decisão operacional, não apenas estatística.

E. Visualização Comparativa

A Figura 1 apresenta a evolução da acurácia e do recall em cenários adversos selecionados, além do impacto percentual de cada perturbação na perda de recall. A visualização não representa todos os 20 testes, mas destaca os cenários mais relevantes para análise de robustez.

A figura reforça que a acurácia global mascara variações importantes da sensibilidade do modelo. O impacto do SMOTE foi o mais expressivo entre os cenários destacados, seguido pela remoção da variável de idade da conta e pelos cenários de

camuflagem e ruído. Esse resultado sustenta a necessidade de avaliar técnicas de balanceamento não apenas pelo equilíbrio numérico entre classes, mas também pelo efeito sobre as fronteiras de decisão.

F. Privacidade e Risco de Inferência de Membro

A pseudonimização adotada no projeto reduz a exposição direta de identificadores pessoais no pipeline enriquecido, mas não constitui defesa formal contra ataques de inferência de membro. Conforme demonstrado por Shokri *et al.* [2], modelos podem revelar indiretamente informações sobre seus dados de treinamento por meio de seus padrões de predição. Esse risco é particularmente relevante quando há sobreajuste ou quando o modelo retorna probabilidades detalhadas.

O framework proposto por Yang *et al.* [6] aponta uma direção mais robusta para trabalhos futuros: gerar dados sintéticos privados antes do treinamento, utilizando VAE e perturbação no espaço latente. Essa estratégia é conceitualmente mais adequada para reduzir risco de vazamento do que apenas substituir identificadores diretos. No entanto, sua adoção exigiria medir simultaneamente utilidade preditiva e resistência a ataques, o que não foi realizado neste estudo.

G. Ameaças à Validade e Limitações dos Resultados

As principais limitações experimentais são:

- Uso da base Kaggle como ponto de partida, com enriquecimento sintético de atributos comportamentais que não existem originalmente no conjunto público;
- Possível dependência entre as regras usadas para simular cenários fraudulentos e os atributos fornecidos ao classificador;
- Ausência de validação temporal, que seria mais adequada para simular implantação em produção;
- Ausência de separação por cliente, o que poderia permitir que padrões de um mesmo usuário sintético aparecessem em treino e teste;




Figura 1. Evolução da acurácia e do recall em cenários adversos selecionados. A acurácia permaneceu próxima de 1.0000, enquanto o recall apresentou maior variação em cenários com remoção de atributo histórico, camuflagem, ruído e oversampling via SMOTE. No cenário avaliado, o ADASYN recuperou o recall, sugerindo potencial benefício de geração sintética adaptativa para amostras de difícil classificação.

- Risco de vazamento temporal em atributos históricos, como *valor_relativo*, caso sejam calculados com informações futuras;
- Uso de cenários simulados, que podem ser mais separáveis do que fraudes reais;
- Ausência de validação cruzada e análise de variância entre diferentes sementes aleatórias;
- Impossibilidade de avaliar formalmente ataques de inferência de membro;
- Ausência de curvas Precision-Recall, PR-AUC e análise sistemática de threshold;
- Potencial redundância entre o *score_heuristico* e os atributos usados para calculá-lo;
- Possível inadequação de SMOTE e ADASYN quando aplicados diretamente a atributos categóricos ou binários codificados numericamente.

Uma ameaça adicional à validade interna está relacionada à possível dependência entre as regras utilizadas para simular determinados cenários fraudulentos e os atributos fornecidos ao classificador. Quando os mesmos sinais empregados na geração dos rótulos ou dos cenários são utilizados como variáveis de entrada, o modelo pode aprender a lógica de simulação, produzindo métricas artificialmente elevadas. Trabalhos futuros devem separar mais rigidamente o processo de geração dos rótulos, os atributos disponíveis ao modelo e os critérios de avaliação.

Essas limitações não invalidam o protótipo, mas delimitam o alcance das conclusões. O estudo demonstra viabilidade técnica em ambiente controlado e enriquecido por simulação, enquanto a generalização para produção exige experimentos adicionais.

V. CONCLUSÃO

Este artigo apresentou uma abordagem híbrida para detecção de fraudes financeiras baseada na integração entre Random Forest, heurísticas de negócio e engenharia de atributos comportamentais. O modelo foi avaliado em 20 cenários controlados, incluindo ataques de velocidade, carding, falhas de autenticação, clientes legítimos de alto valor, dados ausentes, remoção de atributos e estratégias de oversampling.

A base pública *Credit Card Fraud Detection*, do Kaggle, foi utilizada como ponto de partida, mas os atributos comportamentais empregados no modelo foram adicionados por enriquecimento sintético controlado. Dessa forma, os resultados não devem ser interpretados como desempenho direto sobre a base Kaggle original, mas como avaliação de um protótipo híbrido em ambiente experimental.

Os resultados indicaram desempenho elevado na maioria dos cenários, com acurácia próxima de 1.0000 e recall sensível principalmente a situações de remoção de atributo histórico, camuflagem, ruído e oversampling via SMOTE. A comparação entre SMOTE e ADASYN sugeriu que, no cenário avaliado, a geração adaptativa de amostras foi mais adequada para recuperar a sensibilidade do classificador. Ainda assim, essa conclusão deve ser interpretada de forma restrita, pois não foram realizados testes estatísticos em múltiplos datasets.

O estudo também evidenciou que o *score_heuristico* possui valor como mecanismo de incorporação de conhecimento de domínio e interpretabilidade. Entretanto, os experimentos de ablação indicaram que o modelo pode reconstruir parte da lógica heurística a partir de atributos correlacionados. Portanto, trabalhos futuros devem comparar explicitamente heurística isolada, modelo puramente estatístico e abordagem híbrida sob validação temporal e separação por cliente.

Como limitações principais, destacam-se o uso de cenários simulados, a ausência de split temporal, a ausência de vali-

dação por cliente, a inexistência de avaliação formal contra ataques de inferência de membro, a falta de curvas Precision-Recall, a possibilidade de vazamento temporal em atributos históricos e a dependência potencial entre regras de simulação e atributos de decisão. Para escalar o projeto, recomenda-se: validação em base transacional real com janela temporal, análise de drift, calibração de probabilidades, ajuste de threshold por custo operacional, uso de PR-AUC, comparação com modelos de gradient boosting, aplicação de técnicas de explicabilidade como SHAP, avaliação de SMOTENC para dados mistos e investigação de dados sintéticos privados com VAE-DP ou CTGAN.

Conclui-se que a combinação de conhecimento de domínio e aprendizado supervisionado é uma direção promissora para sistemas antifraude, desde que acompanhada por validação rigorosa, análise crítica de métricas e mecanismos de governança de dados compatíveis com a sensibilidade do domínio financeiro.

REFERÊNCIAS

- [1] F. K. Alarfaj, I. Malik, H. U. Khan, N. Almusallam, M. Ramzan, and M. Ahmed, "Credit card fraud detection using state-of-the-art machine learning and deep learning algorithms," *IEEE Access*, vol. 10, pp. 39700–39715, 2022, doi: 10.1109/ACCESS.2022.3166891.
- [2] R. Shokri, M. Stronati, C. Song, and V. Shmatikov, "Membership inference attacks against machine learning models," in *Proc. 2017 IEEE Symposium on Security and Privacy (SP)*, San Jose, CA, USA, 2017, pp. 3–18, doi: 10.1109/SP.2017.41.
- [3] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.
- [4] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002, doi: 10.1613/jair.953.
- [5] H. He, Y. Bai, E. A. Garcia, and S. Li, "ADASYN: Adaptive synthetic sampling approach for imbalanced learning," in *Proc. 2008 IEEE International Joint Conference on Neural Networks*, Hong Kong, China, 2008, pp. 1322–1328, doi: 10.1109/IJCNN.2008.4633969.
- [6] R. Yang, J. Ma, Y. Miao, and X. Ma, "Privacy-preserving generative framework against membership inference attacks," *arXiv preprint arXiv:2202.05469*, 2022, doi: 10.48550/arXiv.2202.05469.
- [7] Machine Learning Group – ULB, "Credit Card Fraud Detection," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>. Accessed: May 23, 2026.
- [8] A. A. Taha and S. J. Malebary, "An intelligent approach to credit card fraud detection using an optimized light gradient boosting machine," *IEEE Access*, vol. 8, pp. 25579–25587, 2020, doi: 10.1109/ACCESS.2020.2971354.
- [9] F. A. Ghaleb, F. Saeed, M. Al-Sarem, S. N. Qasem, and T. Al-Hadhrani, "Ensemble synthesized minority oversampling-based generative adversarial networks and random forest algorithm for credit card fraud detection," *IEEE Access*, vol. 11, pp. 89694–89710, 2023, doi: 10.1109/ACCESS.2023.3306621.
- [10] T. Huang, G. Cheng, and K. Huang, "Using variational auto encoding in credit card fraud detection," *IEEE Access*, vol. 8, pp. 149841–149853, 2020, doi: 10.1109/ACCESS.2020.3015600.