

Inteligência Artificial II
Curso: Engenharia da computação
Prof.: Renato Luciano Cagnin
Data: 25/05/2026

Desenvolvimento de um Sistema Híbrido de Detecção de Fraude: Unindo Heurísticas de Negócio, Machine Learning e anonimização de dados sensíveis

Caroline da Silva Grizante Ra:114105
Emilly Emanuely R. dos Santos Ra:114095
Marcela Lovatto Ra:113626

Fundação Hermínio Ometto
Araras-SP

Sumário

1. Introdução	pág.02
2. Objetivo	pág.02
3. Pré-processamento e Privacidade: Anonimização Ética de Dados.....	pág.02
3.1 A Técnica de Hash e Mascaramento.....	pág.02
3.2 Por que não remover os dados totalmente?.....	pág.02
4. Metodologia: O Modelo Híbrido e a Necessidade da Heurística.....	pág.03
5. A Engenharia da Heurística Mestra: O Motor de Decisão Híbrido.....	pág.03
5.1 A Lógica dos Sinais de Alerta (Agravantes de Risco).....	pág.03
5.2 A Lógica dos Fatores de Confiança (Atenuantes de Risco).....	pág.04
5.3 Por que estas métricas superam as tradicionais?.....	pág.04
5.4 O Impacto no Modelo de Machine Learning.....	pág.05
6. Testes.....	pág.05
6.1 O Alerta Noturno e o Vies Geográfico.....	pág.05
6.2 A Neutralização da Idade.....	pág.05
6.3 O Perfil de Gasto e a Inteligência do Valor Relativo.....	pág.06
6.4 Resiliência em Cenários de Caos (Dados NaN e Sujos).....	pág.06
6.5 Invasão de Contas Antigas.....	pág.07
6.6 Cliente VIP e a Redução de Falsos Positivos.....	pág.07
6.7 O Prejuízo Invisível: O Ataque de Carding.....	pág.08
6.8 Robô vs. Erro Humano: O Stress de Velocidade Final.....	pág.09
6.9 Oversampling com SMOTE.....	pág.09
6.10 ADASYN.....	pág.10
6.11 Comparação do Recall entre alguns testes	pág.11
6.11.1 Análise da Evolução de Performance.....	pág.11
6.11.2 Análise do Ranking de Impacto.....	pág.12
7. A Dualidade das Métricas: Acurácia vs. Recall.....	pág.13
7.1 O Mito da Acurácia de 100%.....	pág.13
7.2 O Recall: A Métrica de Ouro.....	pág.13
8. Conclusão	pág.14
9. Referências	pág.15

1. Introdução

A detecção de fraude em sistemas financeiros evoluiu de simples regras estáticas para modelos complexos de Inteligência Artificial (IA). No entanto, modelos puramente estatísticos muitas vezes falham em capturar o "contexto" humano, gerando atritos com clientes legítimos. Este artigo descreve a construção de um sistema híbrido, que combina a interpretabilidade das heurísticas com a capacidade preditiva da Random Forest.

2. Objetivo

O objetivo central foi desenvolver um modelo resiliente capaz de:

1. Minimizar falsos positivos (evitar bloquear o bom cliente).
2. Detectar padrões de ataques modernos (Carding e Invasão de Conta).
3. Manter a performance em cenários de desequilíbrio extremo de classes (0,4% de fraude).

3. Pré-processamento e Privacidade: Anonimização Ética de Dados

Antes de qualquer análise estatística ou treinamento da Inteligência Artificial, o sistema passa por uma camada crítica de Segurança por Design (Privacy by Design). O objetivo aqui é garantir que o modelo aprenda padrões comportamentais e não identidades civis, protegendo a privacidade dos usuários em conformidade com a LGPD e o GDPR.

3.1 A Técnica de Hash e Mascaramento

Diferente de uma limpeza manual, o código executa uma função de transformação automática logo na carga dos dados. Informações sensíveis, como o nome completo do cliente, passam por um processo de anonimização onde:

1. Identificadores Diretos: Nomes como "Caroline Grizante" ou "João Silva" são convertidos em identificadores alfanuméricos únicos (ex: C_6406 ou J_9921).
2. Preservação da Integridade: Embora a identidade real seja ocultada, o sistema mantém o vínculo entre as transações de um mesmo ID anonimizado. Isso permite que a IA entenda que "o cliente X" está mudando seu padrão de consumo, sem nunca saber quem é o "cliente X" no mundo real.

3.2 Por que não remover os dados totalmente?

A remoção total dos nomes impediria a análise de recorrência. A anonimização garante que o motor de fraude possa calcular o valor_relativo (comparando a compra atual com o histórico do ID) sem violar o sigilo bancário. Este pré-processamento garante que,

mesmo em caso de vazamento do banco de dados de treinamento, nenhuma informação pessoal seria exposta, pois a chave de decodificação permanece isolada do ambiente de Machine Learning.

4. Metodologia: O Modelo Híbrido e a Necessidade da Heurística

Inicialmente, observou-se que a IA tendia a "chutar" ou sofrer de overfitting em variáveis específicas, como a idade da conta, quando não possuía um guia lógico. Para corrigir isso, implementamos uma Heurística de Negócio.

A heurística atua como um "pré-filtro" de inteligência. Em vez de a IA tentar adivinhar o peso de uma transação internacional, nós fornecemos um score_heuristico baseado em regras de especialistas.

Por que mudar para o híbrido? Sem a heurística, a IA ignorava contextos subjetivos (como um VIP viajando). Com a heurística, transformamos regras de negócio em números que o algoritmo entende perfeitamente.

5. A Engenharia da Heurística Mestra: O Motor de Decisão Híbrido

A função `heuristica_mestra_ultra` opera como um sistema de pontuação dinâmica (Scoring System). O objetivo não é apenas identificar a fraude, mas quantificar a anomalia comportamental. Cada transação nasce com um score zero, e as regras aplicadas servem para "provar" se ela é criminosa ou legítima.

5.1. A Lógica dos Sinais de Alerta (Agravantes de Risco)

```
# --- SINAIS DE ALERTA (Aumentam o Score) ---
if row['pais_diferente'] == 1: score += 4      # Transação internacional
if row['falha_autenticacao'] > 5: score += 6    # Possível robô/força bruta
if row['ataque_velocity'] == 1: score += 7      # Muitas transações em sequência
if row['valor_relativo'] > 5: score += 6        # Gasto muito acima do padrão do cliente
if row['idade_conta_dias'] < 30: score += 5     # Contas novas são mais arriscadas
if row['transacao_noturna'] == 1: score += 3    # Transação em horários de baixo monitoramento
if row['cartao_novo'] == 1: score += 4         # Primeiro uso do cartão físico/virtual
if row['risco_estabelecimento'] == 2: score += 5 # Local já marcado como perigoso

# --- FATORES DE CONFIANÇA (Reduzem o Score) ---
if row['tipo_autenticacao'] == 'biometria': score -= 6 # Biometria é altíssima segurança
if row['tipo_autenticacao'] == '2FA': score -= 3      # Autenticação de dois fatores
if row['idade_conta_dias'] > 1000: score -= 4         # Cliente antigo/fiel

return score
```

Nesta seção, o código busca assinaturas clássicas de ataques:

- Ataque de Velocity (Score +7): É o maior peso individual. Foi escolhido porque transações em sequência rápida são a marca registrada de robôs de carding. A

detecção imediata aqui evita o prejuízo acumulado, sendo mais eficiente do que olhar janelas de 24 horas.

- Falha de Autenticação (Score +6): Ao detectar mais de 5 erros, o código identifica uma tentativa de "força bruta". É a regra que diferencia o robô do humano.
- Valor Relativo (Score +6): Aqui o sistema deixa de ser genérico. Se um cliente que gasta R\$100 repentinamente gasta R\$600, o score sobe. Isso protege contra o uso indevido de cartões por terceiros que tentam "limpar" o limite disponível.
- Geografia e Temporalidade (Score +4 e +3): Transações internacionais e noturnas aumentam o risco, mas não o suficiente para um bloqueio automático, evitando falsos positivos desnecessários.
- Contexto de Conta e Cartão (Score +5 e +4): Contas com menos de 30 dias ou cartões recém-emitados recebem atenção redobrada, pois estatisticamente são os alvos preferenciais para fraudes de primeiro uso.

5.2. A Lógica dos Fatores de Confiança (Atenuantes de Risco)

Este é o diferencial do modelo híbrido: a capacidade de "perdoar" uma transação suspeita se houver provas de legitimidade.

- Biometria (Score -6): É o redutor mais forte. Se o usuário confirmou a identidade via digital ou reconhecimento facial, o sistema reduz drasticamente o risco, permitindo que até transações internacionais de alto valor sejam aprovadas sem atrito.
- Antiguidade (Score -4): Um cliente com mais de 1.000 dias de casa possui um histórico de confiança que serve como um amortecedor contra bloqueios indevidos.

5.3. Por que estas métricas superam as tradicionais?

Diferente de modelos que monitoram "transações por dia" ou "dia da semana", nossa heurística foca na intenção técnica:

1. Imediatez: Detectamos o ataque no primeiro minuto (via Velocity e Falha de Autenticação), enquanto métricas de 24 horas só perceberiam o golpe quando o dano já fosse grande.
2. Adaptabilidade: O valor_relativo entende que o "normal" é diferente para cada pessoa.
3. Resiliência: Como visto nos Ciclos 5 e 6, mesmo que o sistema perca dados históricos, estas regras baseadas na transação atual garantem que o Recall (capacidade de captura) permaneça alto.


5.4.O Impacto no Modelo de Machine Learning

Ao passar o resultado desta função (score_heuristico) como uma feature para a Random Forest, nós damos ao algoritmo um "atalho" de inteligência. Em vez de a IA ter que aprender do zero que "muitas falhas de senha é ruim", nós já entregamos essa conclusão mastigada. Isso explica por que, em todos os nossos gráficos de importância, o score_heuristico aparece no topo: ele é a destilação da experiência humana convertida em poder computacional.

6. Testes


6.1. O Alerta Noturno e o Vies Geográfico (Base 20k)

O teste inicial buscou validar a sensibilidade do modelo a transações realizadas entre 22h e 06h sem autenticação robusta. No código, implementamos a flag transacao_noturna, atribuindo um peso moderado ao score. O gráfico resultante revelou que a IA rapidamente elegeu o horário e a divergência de países como os principais preditores. A matriz de confusão apresentou precisão absoluta, mas acendeu um alerta: o modelo estava tornando-se "preconceituoso" com o período noturno, o que motivou os ajustes seguintes.




6.2 A Neutralização da Idade e a Quebra da Muleta Estatística

Nestes ciclos, removemos propositalmente a variável idade_conta_dias. O objetivo era testar se o modelo conseguiria manter a performance sem saber há quanto tempo o cliente possuía a conta. No código, forçamos a análise a depender exclusivamente do comportamento imediato. Os gráficos de importância mostraram o score_heuristico assumindo o protagonismo. A IA provou que, mesmo "cega" para o histórico, a lógica de negócio inserida manualmente era suficiente para manter os 100% de acerto.



6.3. O Perfil de Gasto e a Inteligência do Valor Relativo (Base 30k)


Aqui, o código foi enriquecido com a métrica `valor_relativo`, comparando a compra atual com o `valor_historico_medio` do cliente. Também introduzimos o `ataque_velocity`. O gráfico de importância sofreu uma alteração profunda: a IA parou de olhar para o valor bruto da transação e passou a priorizar a "estranheza" do gasto. Isso permitiu que compras caras de clientes ricos passassem, enquanto compras médias de clientes com perfil de gasto baixo fossem barradas.



6.4. Resiliência em Cenários de Caos (Dados NaN e Sujos)


Simulamos uma falha de sistema injetando valores nulos e dados corrompidos. No código, utilizamos o `SimpleImputer` para preencher as lacunas com a mediana, garantindo que o algoritmo não travasse. O gráfico "O que a IA achou importante?" demonstrou uma reorganização automática: na ausência de dados de perfil, a IA deu peso máximo à

falha_autenticacao. A resiliência foi confirmada pela manutenção da precisão, mesmo sob degradação técnica.



6.5. Invasão de Contas Antigas e o Fim da Confiança Cega


Estes testes focaram em fraudadores que compram contas veteranas. No código, neutralizamos novamente a idade da conta para forçar a IA a desconfiar de comportamentos suspeitos em perfis "seguros". Os resultados gráficos mostraram a idade_conta_dias caindo para a base da pirâmide de relevância, enquanto o score_heuristico consolidou-se como o filtro mestre, provando que um comportamento de ataque anula qualquer tempo de fidelidade.



6.6. O Paradoxo do Cliente VIP e a Redução de Falsos Positivos


O cenário simulou um cliente antigo realizando uma compra de luxo na França. O risco geográfico e financeiro era máximo. No código, inserimos um "salvo-conduto": if

biometria: score ≥ 6 . O gráfico da matriz de confusão validou a tese: o modelo não gerou falsos positivos. A IA entendeu que a prova de vida (biometria) superava o risco da localização internacional, garantindo a liberdade do cliente legítimo.



6.7. O Prejuízo Invisível: O Ataque de Carding


Simulamos 500 transações de R\$1,00 em alta velocidade. No código, o foco foi a variável `ataque_velocity`. Gráficos de modelos comuns costumam ignorar esses valores baixos, mas o nosso gráfico de importância elevou o valor ao topo pela primeira vez, não pelo montante, mas pela repetição mecânica. A IA identificou com sucesso o padrão de robôs testadores de cartões, algo que passaria despercebido por regras de valor mínimo.



6.8. Robô vs. Erro Humano: O Stress de Velocidade Final

O teste seguinte comparou um robô (20 tentativas) com um humano esquecido (4 tentativas). No código, definimos o limiar crítico: if falhas > 5: score $\neq 6$. O gráfico final

corroeu o `score_heuristico` e a `falha_autenticacao` como os pilares supremos. A matriz de confusão mostrou que o sistema foi capaz de ter "empatia" com o humano, permitindo que ele acertasse a senha na quarta tentativa, enquanto bloqueou o robô impiedosamente na vigésima, atingindo o F1-Score de 0.97 em uma base de 50 mil dados.




6.9 Oversampling com SMOTE

Em cenários reais de detecção de fraude, a base de dados é inerentemente desbalanceada (o que chamamos de Imbalanced Data), onde as transações legítimas superam as fraudulentas em uma proporção de centenas para uma. Conforme observado nos testes iniciais, esse desequilíbrio pode induzir o modelo ao erro sistemático de classificar tudo como 'legítimo' para obter uma acurácia alta, negligenciando a classe minoritária (fraude).

Para mitigar essa tendência e forçar o algoritmo a aprender as nuances do crime, aplicou-se a técnica de Oversampling via SMOTE (Synthetic Minority Over-sampling Technique). Diferente da duplicação simples de dados, o SMOTE utiliza um algoritmo de vizinhos próximos para gerar 'fraudes sintéticas'. Ele cria novos pontos de dados no espaço vetorial que se situam entre as características das fraudes reais, preenchendo lacunas estatísticas sem repetir exatamente os mesmos registros.

Com a aplicação desta ferramenta, o banco de dados foi artificialmente equilibrado em uma proporção de 50% legítimos e 50% fraudes. Tecnicamente, isso permitiu a remoção do parâmetro `class_weight` do modelo Random Forest. Uma vez que as classes possuem o mesmo peso numérico no conjunto de treinamento, o algoritmo passa a tratar ambos os


eventos com a mesma prioridade, eliminando a necessidade de 'avisar' manualmente à IA sobre a importância da fraude através de pesos de penalização."



Contudo, os resultados tabulados no experimento revelaram uma queda no Recall para 95.00%, a menor marca registrada nesta pesquisa. Este fenômeno sugere que, embora o SMOTE resolva o problema do desequilíbrio numérico, ele pode introduzir um 'ruído de vizinhança', onde as fraudes sintéticas acabam sobrepondo-se aos limites das transações legítimas (VIPs), dificultando a separação clara que a Heurística proporcionava anteriormente.


6.10 ADASYN

Enquanto o SMOTE gera dados sintéticos de forma uniforme entre os exemplos da classe minoritária, o ADASYN adota uma abordagem muito mais inteligente e adaptativa. O grande trunfo desta técnica, que justifica o retorno ao patamar de 100% de Recall, é a sua capacidade de focar onde a dificuldade é maior. O ADASYN utiliza um coeficiente de densidade para identificar quais exemplos de fraude estão cercados por transações legítimas (áreas de alta densidade da classe majoritária). Em termos práticos, o algoritmo entende que essas são as fraudes mais 'difíceis' de detectar, pois elas se camuflam melhor no comportamento normal. A partir dessa identificação, o ADASYN gera mais dados sintéticos para essas áreas críticas e menos para as áreas onde a fraude já é óbvia.



6.11 Comparação do Recall entre alguns testes

6.11.1 Análise da Evolução de Performance




O gráfico de evolução demonstra a robustez do modelo Random Forest ao longo de 15 cenários distintos. A linha azul, representante da Acurácia Geral, mantém-se em um

patamar de estabilidade próximo a 100%, indicando que a capacidade do modelo em classificar transações legítimas (a grande massa dos dados) é praticamente infalível.

Contudo, a análise do Recall (linha vermelha) revela os pontos críticos da operação. Observa-se que até o 10º teste, o modelo opera em estado de perfeição preditiva. A partir do 11º cenário, onde foram injetados 'clientes VIP' e 'invasões de contas antigas', ocorre uma queda controlada na sensibilidade.

Essa oscilação é tecnicamente positiva, pois demonstra que o modelo não está sofrendo de overfitting (decoreba), mas sim reagindo a tentativas sofisticadas de camuflagem de fraude. O ponto de menor desempenho (Teste 14º) coincide com a aplicação da técnica sintética SMOTE, sugerindo que, para este ecossistema, o dado real é superior ao dado gerado artificialmente."

6.11.2 Análise do Ranking de Impacto



O gráfico de barras permite identificar quais variáveis e técnicas de processamento mais desafiaram a Inteligência Artificial. Este ranking é fundamental para a gestão de riscos,

pois isola os vetores de vulnerabilidade. O maior impacto negativo foi observado no cenário de Oversampling (SMOTE), com uma queda de 5% no Recall.

Academicamente, este resultado é de suma importância: ele comprova que, ao tentar balancear o banco de dados de forma sintética, houve uma sobreposição de classes que 'confundiu' as fronteiras de decisão da IA. Em segundo lugar, aparecem os cenários de Caos Absoluto e Ruído, onde a perda de 2,56% no Recall reflete o impacto de dados nulos e fraudes camufladas em perfis de clientes antigos. Este gráfico valida a tese de que a qualidade da engenharia de atributos (features) é o principal escudo do modelo, sendo mais impactante que o volume total de dados processados."

7. A Dualidade das Métricas: Acurácia vs. Recall no Contexto de Fraude

7.1 O Mito da Acurácia de 100%

Nos ciclos de teste, especialmente no Ciclo 7 (50k dados), observamos uma acurácia de 99.98%. Em qualquer outro software, isso seria o sucesso absoluto. No entanto, na detecção de fraude, a acurácia isolada é uma métrica perigosa.

Como as fraudes representam apenas 0,4% do nosso banco de dados, se o modelo simplesmente decidisse que "ninguém é fraudador", ele ainda teria uma acurácia de 99,6%. Ou seja, o modelo estaria "acertando" quase tudo, mas falhando em sua única missão: parar o crime. Por isso, usamos a acurácia apenas como um indicador de estabilidade geral, mas nunca como o veredito final.

7.2 O Recall: A Métrica de Ouro

O Recall (também chamado de Sensibilidade) responde à pergunta: "De todas as fraudes que realmente aconteceram, quantas o modelo foi capaz de capturar?". No nosso teste final, atingimos um Recall de 0.95 (95%). Isso significa que, em um mar de 40 fraudes escondidas entre 10.000 transações de teste, o modelo "pescou" 38 delas.

Perder apenas 2 fraudes em um cenário de estresse tão alto é um resultado excepcional. No código, o Recall foi impulsionado pelo uso do `class_weight='balanced_subsample'`, que forçou a IA a dar o mesmo peso para as poucas fraudes que deu para as milhares de transações legítimas. Sem esse ajuste, o Recall cairia drasticamente, pois a IA ignoraria os "pontos fora da curva".

Integração nos Testes Específicos

- No Ciclo 9 (Carding): O Recall foi vital. Como as transações eram de apenas R\$1,00, a IA precisava de um Recall altíssimo para não deixar que centenas de pequenos golpes passassem despercebidos. O código focado em ataque_velocity garantiu que o Recall não fosse sacrificado pelo valor baixo da compra.
- No Ciclo 10 (Robô vs. Humano): Aqui buscamos o equilíbrio entre Precision (não bloquear o humano) e Recall (barrar o robô). Ao definirmos a heurística de falha_autenticacao > 5, garantimos que o Recall de ataques de força bruta fosse de 100%, sem destruir a experiência do usuário real.

8. Conclusão

Este trabalho apresentou um sistema híbrido para a detecção de fraude, combinando a robustez do Machine Learning, especificamente a Random Forest, com a inteligência e a interpretabilidade das heurísticas de negócio. A abordagem proposta demonstrou ser eficaz na minimização de falsos positivos, na detecção de padrões de ataques modernos como Carding e Invasão de Conta, e na manutenção da performance em cenários de desequilíbrio extremo de classes.

A integração de heurísticas, como o score_heuristico, provou ser crucial para fornecer ao modelo de IA um 'atalho' de inteligência, permitindo que ele compreendesse contextos subjetivos e se adaptasse a cenários complexos, como o 'Paradoxo do Cliente VIP'. Além disso, o artigo destacou a importância da anonimização ética de dados através de técnicas de hash e mascaramento, garantindo a conformidade com a LGPD e o GDPR.

Um dos pilares fundamentais desta investigação foi o tratamento do desbalanceamento de classes através de técnicas de amostragem sintética. A aplicação do SMOTE (Teste 14º) revelou um desafio estatístico importante: embora tenha equilibrado as classes numericamente, gerou uma queda no Recall para 0.95, evidenciando que a geração uniforme de dados pode introduzir ruído nas fronteiras de decisão, especialmente em perfis de fraude mais sofisticados.

Em contrapartida, a introdução da técnica ADASYN demonstrou ser a solução definitiva para este ecossistema. Ao focar a geração de dados sintéticos nas amostras de difícil aprendizagem, o ADASYN permitiu que o modelo recuperasse a sensibilidade máxima, atingindo um Recall de 1.0 (100%). Esta comparação provou que a aprendizagem adaptativa é superior ao balanceamento estatístico simples em ambientes bancários de alta complexidade.

Os testes detalhados validaram que, enquanto a Acurácia se manteve estável em todos os cenários, o Recall consolidou-se como a métrica de ouro. A análise comparativa revelou que o sistema mantém uma resiliência notável mesmo sob 'caos absoluto', flutuando entre 0.97 e 1.0, o que garante uma captura quase total de fraudes reais sem comprometer a experiência do utilizador legítimo.

Em suma, a dualidade entre Precision e Recall foi resolvida pela combinação estratégica de heurísticas de autenticação e amostragem adaptativa. O sistema híbrido desenvolvido oferece uma solução promissora, resiliente e eficaz para os desafios contemporâneos da detecção de fraude, estabelecendo um novo padrão de defesa em profundidade para transações financeiras.

9. Referências

- ALMEIDA, João Paulo; SILVA, Carlos Eduardo. **Detecção de Fraudes Financeiras com Algoritmos de Aprendizado de Máquina: Desafios e Oportunidades**. São Paulo: Editora Blucher, 2021.
- BOLTON, Richard J.; HAND, David J. Statistical Fraud Detection: A Review. **Statistical Science**, v. 17, n. 3, p. 235-249, 2002.
- BRASIL. Lei nº 13.709, de 14 de agosto de 2018. **Lei Geral de Proteção de Dados Pessoais (LGPD)**. Brasília, DF: Diário Oficial da União, 2018.
- BREIMAN, Leo. **Random Forests**. *Machine Learning*, v. 45, n. 1, p. 5-32, 2001.
- CHAWLA, Nitesh V. et al. SMOTE: Synthetic Minority Over-sampling Technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321-357, 2002.
- EUROPEAN UNION. **General Data Protection Regulation (GDPR)**. Regulation (EU) 2016/679. Official Journal of the European Union, L 119, 2016.
- FAWCETT, Tom. An Introduction to ROC Analysis. **Pattern Recognition Letters**, v. 27, n. 4, p. 861-874, 2006.
- GÉRON, Aurélien. **Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras & TensorFlow**. 2. ed. Rio de Janeiro: Alta Books, 2021.
- HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. New York: Springer, 2009.

- HE, Haibo et al. ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning. *In: IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence)*. Hong Kong: IEEE, 2008. p. 1322-1328.
- **OWASP (Open Web Application Security Project)**. OWASP Automated Threats to Web Applications. v. 1.2, 2020.
- PROVENCE, Foster; FAWCETT, Tom. **Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking**. Sebastopol: O'Reilly Media, 2013.
- SALTZER, Jerome H.; SCHROEDER, Michael D. The Protection of Information in Computer Systems. **Proceedings of the IEEE**, v. 63, n. 9, p. 1278-1308, 197